

OSRPC: 基于流数据混合采样的主动学习 餐厨垃圾检测

梁桥康^{1,2}, 郑正月^{1,2}, 舒立业^{1,2*}, 秦 海^{1,2}

(1. 湖南大学电气与信息工程学院, 长沙410082;
2. 机器人视觉感知与控制技术国家工程研究中心, 长沙410082)

摘 要: 餐厨垃圾分拣现场的高动态性和复杂性给目标检测算法的精度带来了巨大挑战。针对复杂背景下目标检测算法标注成本高、流数据中存在的类别不平衡和概念漂移问题, 提出了一种基于流数据混合采样的主动学习餐厨垃圾检测方法 OSRPC。首先, 利用少量标注样本训练 UMAP 降维模型和对抗网络判别器以获得低维特征和图像标注置信度, 用于后续漂移检测和标注判断; 其次, 提出在线主动学习可变阈值样本代表性与效用加权预测一致性混合策略进行样本选择与标注; 然后, 将选择并标注好的样本加入模型训练以提升模型性能。最后, 在餐厨垃圾目标检测数据集 ODKW 上进行实验, 结果表明在相同标注量下所提方法 OSRPC 对模型性能的提升效果优于其他方法。

关键词: 主动学习; 目标检测; 流数据; 概念漂移; 不确定性度量; 样本代表性

中图分类号: TP391.4

文献标识码: A

文章编号: 2096-5915(2025)03-080-09

DOI: 10.19942/j.issn.2096-5915.2025.03.26

OSRPC: Active Learning for Kitchen Waste Detection Based on Hybrid Sampling of Data Streams

LIANG Qiaokang^{1,2}, ZHENG Zhengyue^{1,2}, SHU Liye^{1,2*}, QIN Hai^{1,2}

(1. College of Electrical and Information Engineering, Hunan University, Changsha 410082, China;
2. National Engineering Research Center of Robot Vision Perception and Control, Changsha 410082, China)

Abstract: The high dynamism and complexity of kitchen waste sorting environments pose significant challenges to the precision of object detection algorithms. To address the issues of high annotation costs, concept drift in streaming data, and class imbalance in complex backgrounds, an active learning approach for kitchen waste detection is proposed based on hybrid sampling of streaming data, termed Online method with Sample Representativeness and Prediction Consistency (OSRPC). Initially, a small set of labeled samples is used to train UMAP dimensionality reduction models and adversarial network discriminators to obtain low-

收稿日期: 2025-04-14; 修回日期: 2025-05-31

基金项目: 国家自然科学基金 (62073129)

作者简介: 梁桥康, 博士, 教授。

通讯作者: 舒立业, 硕士研究生。

引用格式: 梁桥康, 郑正月, 舒立业, 等. OSRPC: 基于流数据混合采样的主动学习餐厨垃圾检测[J]. 无人系统技术, 2025, 8 (3): 80-88. LIANG Q K, ZHENG Z Y, SHU L Y, et al. OSRPC: Active learning for kitchen waste detection based on hybrid sampling of data streams[J]. Unmanned Systems Technology, 2025, 8 (3): 80-88.

dimensional features and image annotation confidence levels, which are utilized for subsequent drift detection and labeling judgments. An online active learning strategy that combines variable-threshold sample representativeness with utility-weighted prediction consistency for sample selection and labeling is proposed. Selected and labeled samples are then incorporated into model training to enhance performance. Experiments conducted on the kitchen waste object detection dataset, Object Detection for Kitchen Waste (ODKW) demonstrate that OSRPC outperforms other methods in terms of model performance improvement under identical annotation efforts.

Key words: Active Learning; Object Detection; Streaming Data; Concept Drift; Uncertainty Measurement; Sample Representativeness

1 引言

目标检测是计算机视觉中的重要任务之一。传统的目标检测算法难以满足日益复杂的检测需求,因此基于深度学习的目标检测算法成为了当前的研究热点。深度目标检测算法大多采用有监督的方式训练网络模型,并依赖大量的高质量标注数据。然而,在相当一部分生物学领域以及工业现场如餐厨垃圾处理中,获取标注数据往往需要高昂的人力成本,这限制了深度学习在目标检测任务中的发展。因此,如何筛选具有高信息量的数据进行标注,成为了深度目标检测领域的关键问题之一。

为了有效地获取高信息量样本,研究人员将目光转向了主动学习。主动学习通过设计合适的查询机制来选择富价值的未标注样本,并交由专家进行标注,随后利用这些标注好的样本训练神经网络模型,重复此过程直至模型性能达到要求或标注预算耗尽。其核心在于从大量未标注数据中选择对模型性能提升更有效的样本加入训练^[1],在维持目标检测模型性能要求的前提下,降低标注成本。

近年来,主动学习方法被广泛应用于皮肤癌分类、肺癌筛查和息肉检测等各项医学图像检测领域^[2]和遥感图像识别领域^[3]。此外,研究人员也在积极探索主动学习在其他生产领域的应用可能性。餐厨垃圾在进行集中无害化处理前需要将掺杂在其中的不可分解物质如塑料瓶、金属制品和玻璃制品等识别并分拣出来。传统的人工分拣方式存在环境差、效率低等问题,因此实现主动学习与目标检测应用的结合对助力智能化垃圾分拣具有重要意义。目标检测中的主动学习旨在以

低标注成本实现良好的模型检测性能。在实际应用中,基于流数据的主动学习目标检测任务中还涉及到类别不平衡和概念漂移的问题,使得流数据的检测任务变得更加复杂。类别不平衡导致模型对于少数类的检测效果有限^[4],而概念漂移则表现为模型的输入数据分布随时间推移发生显著变化,当模型遇到与训练阶段不同的数据分布时,其对新出现模式的预测能力将受到严重影响,进而导致整体性能下降。

为了解决目标检测中存在的样本标签稀缺性问题,在考虑主动学习策略可能出现采样偏差的前提下,本文提出了一种基于流数据混合采样的主动学习餐厨垃圾检测方法(Online method with Sample Representativeness and Prediction Consistency, OSRPC),本文的主要贡献如下:

(1) 设计了一种基于流数据的主动学习目标检测框架,能够在有限的标注预算下实现良好的检测性能。

(2) 提出一种可变阈值样本代表性策略,能够及时调整阈值,提高选中漂移样本的概率,增强模型对变化样本的适应性。

(3) 提出一种效用加权预测一致性策略,利用匈牙利匹配预测原始图像与增强图像之间的一致性,并通过给类别上和时间流中的新类赋予更大的权重来提高选中概率。

2 相关工作

本文主要研究了基于流数据的主动学习目标检测方法。下面对基于流数据的主动学习框架、

主动学习策略和概念漂移的研究现状进行总结。

2.1 基于流数据的主动学习通用框架

基于流数据的主动学习是指模型通过合适的策略不断地从连续流入的流数据中选择新的有价值的数据点,以更新模型的参数和行为^[5],属于在线学习的一种形式。根据处理数据的方式不同,可分为两大类:基于单通道的在线主动学习和基于批处理的在线主动学习。

基于单通道的主动学习即时观察并评估每个传入的数据点。在一些视频流和临床实验中,由于用户或志愿者会依次出现,并且可能没有足够的时间积累潜在用户或患者的池,因此必须随时做出决定^[6]。Cano等^[7]开发了一种在线自适应集成方法(Robust Online Self-adjusting Ensemble, ROSE),该方法为每种类别样本配置了一个滑动窗口缓冲区以维护最新的样本。

基于批处理的主动学习方法定期选择一个小批量数据进行标注和训练。Yin等^[8]提出了一种基于群集的主动学习方法,通过调整模型中数据簇的大小,准确反映当前数据分布,最后使用缓冲区来存储新的簇以更新模型参数。Yan等^[9]开发了一种基于聚类的流数据分类方法,并将有效的主动学习方法扩展并嵌入到所提框架中,以最大程度地减少对故障先验知识的需求。以上两种方案均用于图像分类任务中,当前对基于流数据的主动学习目标检测方法的研究相对较少。Manjah等^[10]开发了轻量级的视频目标检测模型,该方法引入了基于流的主动蒸馏,使用主动学习策略选择图像来微调学生模型。此类方法面临的一个主要挑战是如何确定恰当的数据块大小^[11]。

2.2 主动学习策略

基于流数据的主动学习的基本流程是将流数据以逐个或批次的形式提交给查询模块筛选,该模块负责判定是否请求标注当前样本的标签,若不选取则将其丢弃。在对主动学习的研究中,常见的查询策略包括不确定性策略^[12-14]和代表性策略^[15]。不确定性策略是根据模型对样本的不确定性度量来选择。代表性策略旨在选择一个能反映总体或特定区域内的样本分布特征的样本集合。

单独采用不确定性策略或代表性策略的主动

学习方法存在一定的局限性,因此基于混合策略的主动学习^[16]成为了当前的主流研究方向。例如,Yang等^[17]设计了一种即插即用主动学习(Plug and Play Active Learning, PPAL)方法,可以很容易地推广应用到不同的物体检测器上,但该方法没有解决流数据中存在的概念漂移问题。

2.3 概念漂移

在实际环境中,数据分布可能会随着时间的推移而变化,这使得模型难以适应并继续提供准确的预测。目前概念漂移的处理方式大体上可分为主动检测和被动适应两种方法。文献[18]提出了一种基于混合特征提取的概念漂移处理方法,采用时间注意力机制与相似度计算来评估流数据在不同时间点上的重要性,增强了关键特征在时间序列上的表达,从而提升模型应对概念漂移的能力。被动适应方法通过不断调整模型来适应新的数据,不进行概念漂移检测。这种定期更新模型的方式导致时间开销较大^[19]。

3 实验方案

3.1 方法整体框架

本研究针对餐厨垃圾异物分拣场景中存在的概念漂移、类别不平衡及实时性要求等核心挑战,提出了基于流数据混合采样的在线主动学习方法OSRPC。如图1所示,该方法采用双阶段迭代优化框架,第一阶段通过标注初始样本集构建目标检测基线模型,同步训练UMAP(Uniform Manifold Approximation and Projection)特征降维模块与对抗判别网络。

第二阶段创新性地设计动态阈值调控的混合采样策略,通过特征空间判别与效用权重预测一致性相结合的方法,实现有效的样本筛选。首先,提取图像多尺度融合特征输入对抗网络判别器,再基于可变阈值机制筛选潜在空间特征偏离的样本,形成初始候选集。当候选样本数达到动态预算后,通过计算效用加权的预测一致性指标优先标注最具信息量的样本。

第一、二阶段对检测模型进行周期性更新,以适应当前流数据的采样分布和决策边界,提升




图1 OSRPC方法的总体框架

Fig. 1 Overall framework of the OSRPC method

模型性能。

3.2 可变阈值样本代表性策略

通常流数据主动学习对单样本使用固定的阈值判断是否标注样本，这种机制一方面无法及时适应动态变化的流数据分布，另一方面当流数据不确定性较低时选择策略无法发挥作用，甚至可能退化为按采样顺序选择标注样本。因此，为适应餐厨垃圾目标检测任务中流数据的动态变化，本文提出一种可变阈值样本代表性选择策略。样本代表性从对抗判别网络中获得，结构如图2所示，包括骨干网络、多尺度交互的Transformer编码器、双向特征融合网络和对抗网络判别器。

首先骨干网络提取多尺度特征，将最后一层的特征向量传入Transformer编码器，通过前馈网络和多头自注意力获取尺度内实体关系。再将多尺度融合特征 F_5 送入判别器，通过卷积和池化层统一特征维度，全连接层输出潜在空间特征，最后通过两层全连接层、ReLU及Sigmoid激活函数，得到介于0~1之间的标量，作为输入图像是已标注样本的置信度。

在使用该网络推理图像前，需要先训练模型。骨干网络、编码器和融合网络与目标检测主任务

共用，无需单独训练。判别器用于区分已标注样本和未标注样本的潜在空间特征，设计训练的损失函数 $\mathcal{L}_D$ 如下

$$\mathcal{L}_D = -\mathbb{E}[\log(D(F(f_L|x_L)))] - \mathbb{E}[\log(1 - D(F(f_U|x_U)))] \quad (1)$$

式中， D 和 F 分别代表对抗网络判别器和双向特征融合网络；对于已标注图像 x_L 由特征融合网络 F 提取的特征 f_L ， $-\mathbb{E}[\log(D(F(f_L|x_L)))]$ 约束判别器将其判别为已标注样本的概率 $D(F(f_L|x_L))$ 尽可能大，同理 $-\mathbb{E}[\log(1 - D(F(f_U|x_U)))]$ 约束未标注图像 x_U 的特征 f_U 判定为标注数据概率更小。

在基于判别器输出已标注置信度评分的数据标注决策框架中，需要设定合理的阈值，但固定阈值难以事先设定一个合理的值，可能会导致采样偏差。所以，本文采用可变阈值机制动态调整适应变化的流数据，调节过程见算法1。其中 $\tilde{\theta}_{sr}$ 为动态调整的阈值，用于控制样本标注的决策边界，随着流数据的输入和模型反馈自适应调整；随机变量 η 为服从正态分布的随机因子，用于计算代表性阈值时引入可控的随机性。当置信度小于样本代表性阈值 θ_{sr} ，说明判别器认为该图像属




图2 基于Transformer编码器结构的对抗判别网络结构

Fig. 2 Adversarial discrimination network architecture based on transformer encoder structure

于未标注样本的概率较高, 把该图像分为待标注, 并缩减样本代表性阈值。反之, 则表示该图像属于已标注样本的概率较高, 会将阈值进行放大且不再查询标签。

当流数据图像产生较大数据分布变化、尤其是出现概念漂移时, 判别器的特征辨识能力减弱, 导致样本很容易被判定为已标注范畴。而本文提出的策略能及时调整阈值变化, 提升选中漂移样本的概率, 从而增强模型对数据分布变化的适应能力, 即增强主动学习节约标注成本的效用。

算法1 可变阈值样本代表性策略

输入: 当前处理的流数据图像 x_u 的判别器输出已标注置信度 S_{labeled} , 变化阈值 $\tilde{\theta}_{SR}$, 随机变量 $\eta \sim N(1, \delta)$, 阈值调整步长 s

输出: 布尔变量 $\text{to_label} \in \{\text{True}, \text{False}\}$

过程:

- 1: 样本代表性阈值 $\theta_{SR} = \tilde{\theta}_{SR} \times \eta$
- 2: **if** ($S_{\text{labeled}} \leq \theta_{SR}$) **then**
- 3: $\tilde{\theta}_{SR} = \tilde{\theta}_{SR} \times (1 - s)$
- 4: **return** $\text{to_label} \leftarrow \text{True}$
- 5: **else**
- 6: $\tilde{\theta}_{SR} = \tilde{\theta}_{SR} \times (1 + s)$
- 7: **return** $\text{to_label} \leftarrow \text{False}$

3.3 效用加权预测一致性策略

目标检测结果评估中的预测差异分析以目标框匹配为前提, 以往的方法普遍采用交并比

(Intersection Over Union, IOU) 匹配, 然而这种匹配机制只关注单个目标框最优匹配, 对餐厨垃圾这种目标密集且堆叠严重的图像容易引发匹配歧义。针对此局限性, 本文引入基于二分图匹配理论的匈牙利算法, 通过全局最优搜索策略构建唯一确定性匹配关系, 其核心在于建立科学合理的成本矩阵。本文设计同时考虑预测类别分布和边界框坐标差异的成本矩阵 Cost , 定义式为

$$\text{Cost}[i, j] = w_1 \times JS[s_i, s_j] + w_2 \times L1[b_i, b_j] + w_3 \times (1 - \text{GIoU}[b_i, b_j]) \quad (2)$$

式中, 第 $i(j)$ 个目标的检测结果包括框坐标 b_i (b_j) 及类别概率分布 s_i (s_j), $JS[s_i, s_j]$ 表示对类别概率分布 s_i 和 s_j 计算 JS 散度; w_1, w_2, w_3 为三项损失计算权重, 参照文献 [20~21] 分别设置为 2、5、2。采用匈牙利算法全局一对一最优匹配确保整体匹配准确性, 在此基础上设计的成本矩阵同时考量了空间位置和类别分布, 使算法在目标重叠与局部遮挡等复杂条件下展现出更强的鲁棒性。

构建流数据中原始图像 x 和增强图像 $\text{AUG}(x)$ 预测输出结果的相似性评估框架, 将匹配关联成本矩阵值作为匹配框一致性度量, 既实现了检测特征的协同利用, 又节省了计算资源。当一张图像中获得 N 对匹配框时, 为保证预测最困难的目标所属图像被选择, 采用最小一致性准则将实例

级最差值映射为图像级匹配质量指标,将其定义为匹配质量 C_Q ,计算式为

$$C_Q(x) = \max_{1 \leq n \leq N} (\{cost[i, j]_1, \dots, cost[i, j]_n, \dots, cost[i, j]_N\}) \quad (3)$$

式中, $cost[i, j]_n$ 为该图像的 N 对匹配框中的第 n 对的成本矩阵对应值。由于匈牙利算法一对一匹配,当两次对比结果中的检测框数量相差较大且匹配框接近时,式(3)匹配质量值较低,即一致性很高,然而实际情况是预测结果差异大。因此,进一步考虑未匹配框的影响,用匹配框数量占比 C_N 反映,定义为

$$C_N(x) = \frac{N}{\max(N_1, N_2, 1)} \quad (4)$$

式中, N_1 和 N_2 分别为两次预测结果中目标框的数量。为保持预测一致性变化趋势的稳定性和范围可控,对匹配质量 C_Q 做指数处理,以参数 λ 控制衰减程度。另外由于两次均未预测到目标时无法计算成本矩阵,此时赋予图像最高预测一致性,图像 x 的预测一致性表达为

$$C(x) = \begin{cases} 1, & \text{if } N_1 = 0 \text{ 且 } N_2 = 0 \\ (\alpha C_N(x) + \beta e^{-\lambda \times C_Q(x)}) \times (1 - P), & \text{其他} \end{cases} \quad (5)$$

式中, α 与 β 分别为匹配数量 C_N 和匹配质量 C_Q 的权重,满足 $\alpha + \beta = 1$ 。为避免当仅其中一次预测有目标时图像匹配一致性恒等于0,引入惩罚项 P ,定义为

$$P = \begin{cases} \frac{N_1}{N_1 + 1}, & \text{if } N_2 = 0 \text{ 且 } N_1 \neq 0 \\ \frac{N_2}{N_2 + 1}, & \text{if } N_1 = 0 \text{ 且 } N_2 \neq 0 \\ 0, & \text{if } N_1 \neq 0 \text{ 且 } N_2 \neq 0 \end{cases} \quad (6)$$

对原图分别采用水平翻转、马赛克遮挡以及增加高斯噪声等多种增强策略,计算所有增强图像的预测一致性均值作为该图像的预测一致性度量。

流数据原始标注集中存在类别不平衡情况及实验中各类别出现的频率不固定导致模型的检测性能受限于少数类,因此有必要在选择策略中引入类别分布的因素,使所选的样本尽量包含少数类别目标。在此基础上,利用已有标注样本的类

别分布,对图像预测目标的类平均权值计算。另一方面,为保证模型适应当前流数据分布,训练样本应尽量代表最新的数据分布,因此在选取样本时,赋予采集时间更近的样本更大的权重。

图像的类别分布权重和时间衰减权重反映着样本的标注效用。新增类别数量相比已有类别少,所以在更新网络时将效用权重分配给训练样本,使得最新采样的、含少数类,特别是新增类别的样本获得更大的训练权重,最终达到提升模型整体性能的目的。

4 实验结果及分析

4.1 数据集处理

本文采用餐厨垃圾目标检测数据集(Object Detection for Kitchen Waste, ODKW)^[22]。为适配实验室硬件平台需求,将图像分辨率从原始 3256×2724 缩放至 640×480 。实验中训练检测模型的样本按照8:2的比例划分为训练集与验证集。为模拟实际流数据场景中存在的概念漂移现象,将ODKW数据集划分为包含初始类与新类目标,本文根据该数据集的各类别占比,将中频类塑料瓶和最少类鞋子当作新引入类。基于采集时间序列筛选前500张仅含初始6类目标的图像作为初始标注样本,用于模型参数的初始化训练。

4.2 实验设置与评价指标

实验基于Ubuntu20操作系统构建环境,采用Pytorch2.0.1框架实施模型搭建,并采用NVIDIA GeForce RTX 4090 Ti GPU进行加速训练。利用Adam优化器,在0.0001的学习率、批处理大小为16的条件下,对目标检测模型进行了20轮的训练。在线主动学习方法将初始标注样本数量设定为500个,单个样本待标注集初始预算为100个,批量标注预算为50个。样本代表性模块的判别器利用Adam优化器训练,学习率为 2.5×10^{-5} ,可变阈值的初始值及变化步长根据文献[23]分别设置为1.0和0.01。通过参数敏感性实验,确定漂移预算衰减量 δ 、预测一致性策略中涉及的匹配数量权重 α 、匹配质量指数控制系数 λ 分别为5、0.5和1.0。

当预测边界框与真实边界框的 IOU 达到 50% 时,认为预测是合理的。依照 MS COCO 数据集评价规则,本文采用 AP_{50} 、mAP 和 mAR 指标来评价模型的检测性能。

4.3 流数据主动学习对比实验

采用先进的 PAL+FS. B 方法^[24]、Vessal 框架^[25]以及基线随机采样 Random 方法进行对比实验,验证本文所提方法的有效性。如表 1 所示,除了评估模型整体性能的指标 mAP、 AP_{50} 和 mAR 外,还包含新类别塑料瓶和鞋子的 mAP,结果均为三次实验结果的平均值,最好结果加粗表示。不同方法在目标检测指标上的三次实验性能比较(均值±标准差)如图 3 所示。

表 1 ODKW 数据集上各类流数据主动学习方法比较结果
Table 1 Comparison results of various stream-based active learning methods on the ODKW dataset

方法	mAP	AP_{50}	mAR	塑料瓶	鞋子
Random	47.17	53.90	88.37	26.84	23.85
FS.B+PAL	48.81	55.58	87.84	32.14	31.58
Vessal	52.36	59.23	88.32	65.05	24.01
OSRPC	60.88	69.53	88.37	68.53	80.03

从表 1 和图 3 中可以看出,本文所提方法的综合检测性能最优,其中 mAP 和 AP_{50} 比 Vessal 方法分别高出 8.52% 和 10.3%,且误差范围较小,反映了所提方法在餐厨垃圾目标检测中有较强的鲁棒性。OSRPC 方法在塑料瓶上的检测精度比




图 3 不同方法在目标检测指标上的性能比较(均值±标准差)
Fig. 3 Performance comparison of different methods on object detection metrics (Mean ± SD)

Vessal 方法高出 3.48%,比 Random 和 FS. B+PAL 均高出 30% 以上,在鞋子类别上的检测精度远高于其他三种方法。

4.4 可视化分析

在对所选样本进行标注并首次重训练模型后,最先采集的包含新增类别目标的图像检测结果如图 4 所示,其中不同类别目标的检测框用不同颜色显示,对应关系为:waste bag (橙色)、metal (石蓝色)、shoe (绿色)、other plastic (蓝色)、plastic bottle (红色)、carton (紫色)、tetra pak (棕色)、glass (黑色)。从图 4 中可以看出,所提方案 OSRPC 检测出的类别最多,在第一张图像中前三种方法对鞋子均有漏检情况,OSRPC 方法检




图 4 一次检测模型优化后采集的含新增类别的图像检测结果

Fig.4 Detection results of images containing new classes after model optimization

测出了图像中包含的所有鞋子,在第二张图像中另外三种方法都漏检了塑料瓶,OSRPC检测出了塑料瓶且置信度达到0.57,整体来看所提方法对新增类别的检测效果最好且保持了对其他类别的检测性能。

5 结 论

提升流数据场景下的目标检测精度对实现餐厨垃圾中异物智能化分拣具有重要意义。本文提出了一种基于流数据混合采样的主动学习餐厨垃圾检测方法,针对目标检测中样本标注成本高的问题,采用主动学习可变阈值样本代表性与效用加权预测一致性混合策略采样,充分考虑了样本的代表性和不确定性,增加选中漂移样本的可能性,有效缓解了类别不平衡和旧样本遗忘问题。在未来的工作中,将在维持检测精度和标注预算在可控范围内的前提下,增加更多新类别图像,提升方法的泛化性能。

参 考 文 献

- [1] 李雅和, 谢志鹏. 基于最大影响力集合的主动学习方法[J]. 计算机科学, 2025, 52(1): 289–297.
LI Y H, XIE Z P. Active learning based on maximum influence set [J]. Computer Science, 2025, 52(1): 289–297 (in Chinese).
- [2] WANG H, JIN Q, LI S, et al. A comprehensive survey on deep active learning in medical image analysis [J]. Medical Image Analysis, 2024, 95: 103201.
- [3] LIANG D, ZHANG J W, TANG Y P, et al. MUS-CDB: Mixed uncertainty sampling with class distribution balancing for active annotation in aerial object detection [J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1–13.
- [4] QI T, XIE H, LI P, et al. Balanced classification: A unified framework for long-tailed object detection [J]. IEEE Transactions on Multimedia, 2024, 26: 3088–3101.
- [5] GUO H S, ZHANG S, WANG W J. Selective ensemble-based online adaptive deep neural networks for streaming data with concept drift [J]. Neural Networks, 2021, 142: 437–456.
- [6] FOWLER Z, KOKILEPERSAUD K P, PRABHUSHAN-KAR M, et al. Clinical trial active learning [C]//The 14th ACM International Conference on Bioinformatics, Computational Biology, and Health Informatics. New York, USA, October 4, 2023.
- [7] CANO A, KRAWCZYK B. ROSE: Robust online self-adjusting ensemble for continual learning on imbalanced drifting data streams [J]. Machine Learning, 2022, 111(7): 2561–2599.
- [8] YIN C Y, CHEN S S, YIN Z C. Clustering-based active learning classification towards data stream [J]. ACM Transactions on Intelligent Systems and Technology, 2023, 14(2): 1–18.
- [9] YAN X, SARKAR M, LARTEY B, et al. An online learning framework for sensor fault diagnosis analysis in autonomous cars [J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(12): 14467–14479.
- [10] MANJAH D, CACCIARELLI D, STANDAERT B, et al. Stream-based active distillation for scalable model deployment [C]//IEEE Conference on Computer Vision and Pattern Recognition, Vancouver, BC, Canada, June 17–23, 2023.
- [11] JIAO B T, GUO Y A, GONG D W, et al. Dynamic ensemble selection for imbalanced data streams with concept drift [J]. IEEE Transactions on Neural Networks and Learning Systems, 2024, 35(1): 1278–1291.
- [12] 张银芳, 于洪, 王国胤, 等. 一种用于数据流自适应分类的主动学习方法[J]. 南京大学学报(自然科学版), 2020, 56(1): 67–73.
ZHANG Y F, YU H, WANG G Y, et al. An active learning method for data stream adaptive classification [J]. Journal of Nanjing University (Natural Science), 2020, 56(1): 67–73 (in Chinese).
- [13] YUAN T, WAN F, FU M, et al. Multiple instance active learning for object detection [C]//IEEE Conference on Computer Vision and Pattern Recognition, Nashville, TN, USA, June 20–25, 2021.
- [14] 李艳红, 任霖, 王素格, 等. 非平衡数据流在线主动学习方法[J]. 自动化学报, 2024, 50(7): 1389–1401.
LI Y H, REN L, WANG S G, et al. Online active learning method for imbalanced data stream [J]. Acta Automatica Sinica, 2024, 50(7): 1389–1401 (in Chinese).
- [15] CAO X F. A divide-and-conquer approach to geometric sampling for active learning [J]. Expert Systems with Applications, 2020, 140: 112907.
- [16] LIU S M, XUE S, WU J, et al. Online active learning

- for drifting data streams[J]. IEEE Transactions on Neural Networks and Learning Systems, 2023, 34(1): 186–200.
- [17] YANG C, HUANG L, CROWLEY E J. Plug and play active learning for object detection[C]//IEEE Conference on Computer Vision and Pattern Recognition, Seattle, WA, USA, June 16–22, 2024.
- [18] 郭虎升, 刘艳杰, 王文剑. 基于混合特征提取的流数据概念漂移处理方法[J]. 计算机研究与发展, 2024, 61(6): 1497–1510.
- GUO H S, LIU Y J, WANG W J. Concept drift processing method of streaming data based on mixed feature extraction[J]. Journal of Computer Research and Development, 2024, 61(6): 1497–1510 (in Chinese).
- [19] KARIMIAN M, BEIGY H. Concept drift handling: A domain adaptation perspective[J]. Expert Systems with Applications, 2023, 224: 119946.
- [20] ZHAO Y, LV W Y, XU S L, et al. DETRs beat YOLOs on real-time object detection[C]//IEEE Conference on Computer Vision and Pattern Recognition, Seattle, WA, USA, June 16–22, 2024.
- [21] SUN P, ZHANG R, JIANG Y, et al. Sparse R-CNN: An end-to-end framework for object detection [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(12): 15650–15664.
- [22] QIN H, SHU L, ZHOU L, et al. Active learning-DETR: Cost-effective object detection for kitchen waste[J]. IEEE Transactions on Instrumentation and Measurement, 2024, 73: 1–15.
- [23] MALIALIS K, PANAYIOTOU C G, POLYCARPOU M M. Nonstationary data stream classification with online active learning and siamese neural networks[J]. Neurocomputing, 2022, 512: 235–252.
- [24] CASTELLANI A, SCHMITT S, HAMMER B. Stream-based active learning with verification latency in non-stationary environments[C]//The 31st International Conference on Artificial Neural Networks, Bristol, UK, September 6–9, 2022.
- [25] SARAN A, YOUSEFI S, KRISHNAMURTHY A, et al. Streaming active learning with deep neural networks[C]//The 40th International Conference on Machine Learning, Honolulu, Hawaii USA, July 23–29, 2023.